API 参考手册

本文档描述开放平台的检索接口与限流约定。

1. 检索接口

GET /v1/search 支持 top_k 与 score_threshold 两个参数；score_threshold 低于 0.35 的片段默认被丢弃，可通过查询参数覆盖。

返回体里的 score 是余弦相似度，越接近 1 越相关。

2. 限流与配额

对外接口按租户维度限流，默认额度为每分钟 600 次请求、并发 20。额度以滑动窗口统计，超出后返回 429 并附 Retry-After 响应头。

场景	限额	说明
默认	600 次/分钟	所有租户
突发	900 次/分钟	持续不超过 10 秒
企业版	3000 次/分钟	需申请

3. 幂等

所有写操作接口要求 Idempotency-Key 请求头，重复的 key 在 24 小时内返回同一结果，避免网络重试造成重复扣费。

4. 错误码

400 参数错误；401 鉴权失败；429 触发限流；500 服务端异常。

429 响应一定会带 Retry-After，单位是秒。